



**國立臺北科技大學**

**National Taipei University Of Technology**

**電機工程系**

**Department Of Electrical Engineering**

**利用機器學習演算法  
提升小鼠疼痛辨識的準確率**

**專題學生 ：何柏昇 Bo-Sheng Ho**

**指導教授 ：吳昭正 Chao-Cheng Wu**

**日期**

# 摘要

專題名稱： 利用機器學習演算法提升小鼠疼痛辨識的準確率

校所別： 國立臺北科技大學 電機工程系大學部

專題生： 何柏昇

指導教授： 吳昭正 博士

關鍵詞： 臉部特徵識別; 疼痛偵測; 支援向量機; 隨機森林; 機器學習

現今對於測試藥物都以動物試驗為重要流程之一，以止痛劑為例，實驗中透過對動物施打藥劑的方式，並觀察其反應，以衡量藥劑的有效性。然而，動物無法直接透過言語表達，因此在相關領域有許多的文獻在探討，以小鼠的臉部表情偵測疼痛的可行性，但多數實驗還是以專家進行人工評估，評估結果容易因人而異，因此才發展以機器學習進行自動辨識，達到一致的標準。本專題建立在相關文獻上，發現以小鼠的臉部特徵進行疼痛辨識時，因為樣本存在偏差容易導致自動辨識的誤判，所以在原先疼痛辨識的架構上，新增一層的分類器，進行樣本的鑑別以及透過將容易導致誤判的樣本移除來更新資料集，使疼痛辨識的準確率上升。

本專題仿照生成對抗網路的架構，使用兩層分類器，第一層作為樣本的鑑別，第二層作為疼痛辨識。透過鑑別器進行樣本鑑別，以此區分出容易導致誤判的樣本，對資料集進行更新以提升疼痛辨識的準確率，並以機器學習取代神經網路來建構鑑別器，使開發時間能夠大幅縮短。

本專題主要分成三個部分，以個別小鼠、全體小鼠以及未知小鼠進行疼痛辨識，考慮個體差異的情況下，觀察不同的資料集，討論模型對於疼痛預測的準確性以及通用性。其中並分成兩個階段，第一階段討論使用不同的演算法建構鑑別器，如支援向量機與隨機森林的情況下，資料集更新後的數量以及疼痛辨別的準確率是否提升；第二階段針對實驗組與對照組進行比較，觀察實驗的成效，並透過減少樣本數，觀察模型的通用性。

本實驗總共使用六隻小鼠，分別以高速攝影機錄製兩部影片，分別為施打辣椒素前、後，以區分成健康與疼痛，再經由 YOLO 演算法，抓取同時具有雙耳、雙眼以及鼻子特徵的影像，並以特徵點之間的歐式距離以及角度為幾何特徵，訓練支援向量機進行疼痛辨識，並以近期相關論文提出使用卷積神經網路預測小鼠疼痛作為對照組，評估效果。

從實驗結果可得知，使用隨機森林建構鑑別器的情況下，進行容易誤判的樣本鑑別並更新資料集後，並再使用支援向量機進行疼痛辨識，其準確率能夠由 80% 提升至 95%。實驗組與對照組兩者判斷疼痛的結果平分秋色，但前者相較後者能大幅節省時間成本，並當訓練樣本較少時，也能夠維持其效能，較不易發生過擬和的情況，具有較高的通用性。

# 致謝

若想要概括大學四年的精華，那非專題莫屬，從書本上的知識至專題上的實作，需要更多思維上的跳脫，除了旁人的指點迷津，還需要孜孜不倦的自我學習，才能從懵懵懂懂的大學生，蛻變成一名研究生。在這過程當中，首先要特別感謝本專題的指導教授吳昭正教授，總是在我們未知的道路上，豎起一盞明燈，指引我們前進的方向，透過教授與學生互相的討論與碰撞，延伸出更多不可思議的構想，才有本專題的誕生。

製作專題的過程當中，必然時常會發生碰壁的情況，在這當下要特別感謝實驗室的郭廷愷學長，總是不厭其煩地傾聽學弟的煩惱，並細心地教導，傳授書本上沒有的親身經驗，使我總能一次次地突破困境，往前邁進一步，受益匪淺。

最後感謝在實驗室的同學們，雖然沒有一起製作專題，但每次開會都會一同參與討論，並在事後給予我更多的建議，讓我接受到更多面向的聲音，以補足自身的不足，以更全面的思維去面對問題，相信這必然使我在未來能夠面對更多的挑戰。



# 目錄

摘要 .....	1
致謝 .....	2
圖目錄.....	4
第一章 緒論 .....	5
1.1 研究動機與目的 .....	5
第二章 背景知識與理論.....	6
2.1 工具 .....	6
2.1.1 MATLAB.....	6
2.1.2 Scikit-learn .....	6
2.1.3 TensorFlow & Keras.....	6
2.2 演算法 .....	7
2.2.1 YOLO : Real-Time Object Detection[8] .....	7
2.2.2 支援向量機(support vector machine, SVM)[1] .....	7
2.2.3 隨機森林(Random Forests)[3][4][7] .....	8
2.2.4 Inception V3[5][6].....	9
第三章 實驗方法 .....	10
3.1 實驗架構 .....	10
3.2 影像前處理 .....	11
3.3 訓練疼痛辨識器 .....	12
3.3.1 疼痛辨識器( SVM ).....	12
3.3.2 疼痛辨識器( InceptionV3 ) .....	12
3.4 進行疼痛辨識.....	13
3.5 訓練鑑別器 .....	13
3.5.1 鑑別器( Linear SVM ) .....	13
3.5.2 鑑別器( RBF SVM ).....	13
3.5.3 鑑別器( Random Forests ) .....	13
3.6 重新訓練疼痛辨識器.....	14
3.7 進行樣本鑑別.....	14
3.8 重新進行疼痛辨識 .....	14

第四章 實驗成果.....	15
4.1 資料集.....	15
4.2 實驗結果.....	15
4.2.1 個別小鼠.....	15
4.2.2 全體小鼠.....	16
4.2.3 未知小鼠.....	18
第五章 結論.....	19
5.1 總結與未來展望.....	19
第六章 參考文獻.....	20

## 圖目錄

圖 2-1 正臉示意圖.....	7
圖 2-2 SVM 概念圖.....	8
圖 2-3 Random Forests 架構.....	8
圖 2-4 Inception V3 架構.....	9
圖 3-1 實驗架構圖.....	10
圖 3-2 老鼠正臉圖.....	11
圖 3-3 臉部幾何特徵示意圖.....	11
圖 4-1 個別小鼠：疼痛辨識準確率.....	16
圖 4-2 全體小鼠：疼痛辨識準確率.....	17

## 表目錄

表 3-1 InceptionV3 參數.....	12
表 4-1 資料集表格.....	15
表 4-2 個別小鼠：資料集數量表.....	15
表 4-3 全體小鼠：資料集數量表.....	16
表 4-4 未知小鼠：資料集數量表.....	18
表 4-5 未知小鼠：疼痛辨識準確率.....	18

# 第一章 緒論

## 1.1 研究動機與目的

小鼠的疼痛辨識，一直以來都是動物試驗的熱門課題，區分疼痛或健康時，大多數實驗都是以專家進行人工評估，但評估結果容易因人而異，進而發展以機器學習進行自動辨識。因此本專題以實驗室學長的結果往下繼續延伸，根據文獻[1]，將小鼠施打辣椒素前、後的狀態區分成健康與疼痛，分別錄製十分鐘的影片，從影片中找出含有耳朵、眼睛以及鼻子等臉部特徵的影像，並計算臉部特徵點之間的歐式距離與角度等幾何特徵，使用支援向量機( SVM )進行疼痛與健康的分類，其準確率雖可達到 80% 左右，但尚有改善空間，因此本專題以於如何提升疼痛辨識的準確率作為開頭，在一連串問題分析的過程中，發現在進行疼痛辨識前，並沒有針對頭部姿勢進行處理，樣本中或許存在著偏差，所以導致容易誤判。

為了解決頭部姿勢的問題，開始查閱相關等文獻，其中參考 2019 年臉部表情分析的文獻[2]，該作者整理近年來表情分析相關等文獻，其中關於頭部姿勢提出了三種解決方法，其中以隨機森林( Random Forests )的效果最佳。於是為了瞭解如何使用隨機森林來解決頭部姿勢問題，針對文獻[3]、[4]展開深入研究後，得知作者在進行臉部表情分析之前，會使用隨機森林將資料集以臉部的幾何特徵，對頭部姿勢進行分類，化為多個子集，再分別進行表情分析，以解決頭部姿勢的問題。雖然此做法看似效果不錯，但缺點也非常明顯，劃分越多子集將導致資料集內的樣本數量大幅減少，而訓練的成效也將大幅降低。

仔細思考如何解決問題的過程中，察覺可仿照生成對抗網路( GAN )的架構，假設資料集中存在真、假資料，透過訓練一個鑑別器網路，對樣本進行鑑別，進而讓機器學會區分真、假資料。而本專題的資料集中，存在著容易導致誤判的資料，就如同先前提到的假資料，或許可以透過在原先的架構上，新增一個鑑別器，幫助區分容易導致誤判的資料，以提升原先對疼痛辨識的準確率。

將先前提到的隨機森林與辨識器架構進行結合，試著以臉部的幾何特徵去訓練一個分類器作為鑑別器使用，進行容易誤判的樣本鑑別並更新資料集，並且由於只分成兩類，所以能夠大幅避免單一樣本數量過低的情況發生。在過程中透過嘗試使用不同的演算法來建構鑑別器，並討論成效如何，以及對於原先的疼痛辨識的準確率是否有所提升，以此來找出更好的方法，並根據文獻[5]中所提出的方法，以深度學習的卷積神經網路進行小鼠疼痛辨識，將其實踐出來作為本專題的對照組，比較機器學習與深度學習的效果差異。



## 第二章 背景知識與理論

### 2.1 工具

#### 2.1.1 MATLAB

MATLAB 全名為 Matrix Laboratory，是由美國 The MathWorks 公司開發的數學軟體，一般用於演算法開發、資料視覺化、資料分析以及數據分析，並且由於其強大的矩陣運算能力，也常應用於影像處理上，因為圖形能夠以多維矩陣的方式呈現，在本專題中，將其應用在影像的前處理，將老鼠的影片分割成圖片集，以便之後的特徵抓取。

#### 2.1.2 Scikit-learn

Scikit-learn 是用於 Python 的機器學習庫，由 Fabian Pedregosa、Gael Varoquaux、Alexandre Gramfort 和 Vincent Michel 等多位開發者，在 2010 年公開發行。其特徵具有各種分類、回歸和聚集算法，包含了 SVM、Random Forests、GBT 和 k-means 等常用於機器學習的演算法，本專題利用其提供的 API 能夠快速建立分類器，以應用於專題中的分類問題。

#### 2.1.3 TensorFlow & Keras

隨著電腦科學的快速發展下，人工智慧、神經網路和深度學習變得炙手可熱，為了因應其發展，開發出許多開源學習框架，而最耳熟能詳的就是由 Google Brain 開發的 TensorFlow，應用在諸多 Google 商業產品上，並於 2015 年開源許可後，被眾人廣泛使用。但由於其偏向低階的深度學習 API，使用者必須花費較多的時間成本，因此常常搭配更為高階的 Keras 一同使用。

Keras 是一個由 Python 撰寫的開源神經網路庫，其特性在於高階深度學習的 API，能夠為開發者節省下許多的時間，而廣受眾人喜愛。並在 2017 年 Google 的 TensorFlow 團隊決定在 TensorFlow 核心庫中支援 Keras，令使用者能夠更加輕鬆開發神經網路，因此本專題也利用 TensorFlow & Keras 進行架構神經網路。

## 2.2 演算法

### 2.2.1 YOLO： Real-Time Object Detection[8]

經典的物件辨識大多分成三個部分，分別是物件定位、特徵抓取以及影像分類，將三個不同的演算法一同使用以完成物件辨識，每個部份必須要獨立訓練，使訓練過程變得十分緩慢。

YOLO 則是把物件辨識當作一個回歸問題，僅靠一個 CNN 來實現，並且以整張圖片來訓練網路，可以避免傳統物件辨識必須分開訓練的缺點，加快運算速度。

本專題利用 YOLO 來辨識小鼠的耳朵、眼睛以及鼻子等五個臉部特徵，如下圖 2-1 所示，進而從影片中找出正臉的圖片。事實上，大多相關老鼠疼痛的論文都是以 Rodent Face Finder software 來抓取老鼠的臉部特徵，但由於其並非開源軟體，為了節省開發成本，因此才選用 YOLO 來完成特徵抓取。



圖 2-1 正臉示意圖

### 2.2.2 支援向量機(support vector machine, SVM)[1]

支援向量機全名為 support vector machine，又稱作 SVM，其原型是由 Vladimir Vapnik 和 Alexey Chervonenkis 於 1963 年發明的，今日常用於分類與回歸分析中分析資料的監督式學習模型與相關的學習演算法。SVM 能將資料點被視為 P 維向量，並找到 P-1 維的超平面來分開這些點，進而完成分類的工作如下圖 2-2(a)。

只要先將資料以  $\{(x_i, y_i) | x_i \in R^d, i = 1, 2, \dots, n\}$  表示，總共有 n 個樣本，並將結果分類成兩種以  $y_i \in \{-1, 1\}$  表示，就能夠以簡易的數學式去描述資料。

$$f(x_i) = w^T x_i + b$$

$$f(x) = \begin{cases} w^T x + b \geq +1, & \text{為正} \\ w^T x + b \leq -1, & \text{為負} \end{cases}$$

但並不是所有資料都能被線性分類，因此在 1992 年，提出了核函數概念，使 SVM 能夠建立非線性的超平面，應用在非線性的資料上。在本專題中，為了解決分類問題，過程中使用了兩種核函數來建立 SVM，分別是 Linear Kernel 和 Gaussian Radial Basis Function Kernel (RBF)，透過改變核函數的方式，將資料投射至更高維度的空間，以此找到可將資料分開的超平面，如下圖 2-2(b)。



Linear Kernel :  $k(x, y) = \langle x, y \rangle$

RBF Kernel :  $k(x, y) = e^{-\sigma \|x-y\|^2} \quad \sigma \in R - \{0\}$

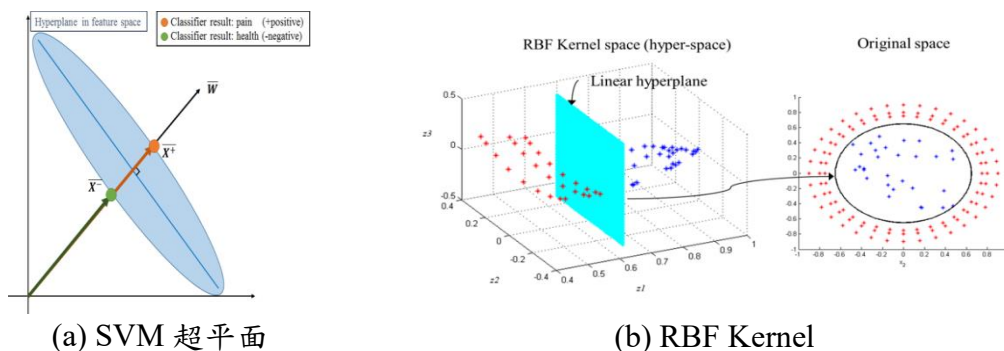


圖 2-2 SVM 概念圖

### 2.2.3 隨機森林(Random Forests)[3][4][7]

Random Forests 這個術語於 1955 年由何天琴所提出的 random decision forests 而來，並於 2001 年由 Leo Breiman 和 Adele Cutler 發展出演算法。其原理在於結合多棵決策樹，並加入隨機分配的訓練資料，由許多不同的決策樹所組成的一個學習器，透過結合多個弱學習器，來建構一個強學習器，如下圖 2-3 所示，而 Random Forests 主要由兩個演算法組成，Bagging 與 Decision Tree。

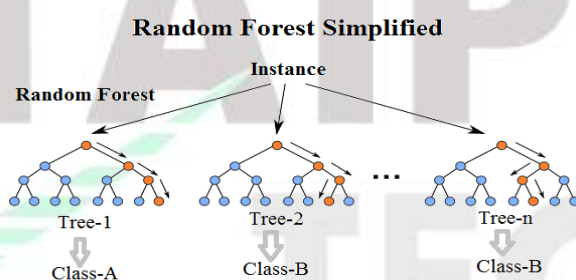


圖 2-3 Random Forests 架構

大部分的實驗都只有一個數據集，而要產生多棵具有差異性的決策樹，就必須要產生不同的數據集，而 Bagging 就是一種解決方式。給定訓練集  $X = x_1, \dots, x_n$  和目標  $Y = y_1, \dots, y_n$ ，從訓練集中放回性採樣重複  $B$  次，以此來訓練  $B$  棵決策樹。

在訓練結束後，對未知樣本  $x$  的預測可以通過對所有單棵回歸樹的預測選擇多數投票或求平均來實現：

$$\hat{f} = \frac{1}{B} \sum_{b=1}^B f_b(x')$$

## 2.2.4 Inception V3[5][6]

Inception V3 是一個卷積神經網絡( Convolutional neural network, CNN )，用於圖片分析或是物件辨識，由 Google 於 2015 提出，其為 GoogLeNets 的第三版，其架構如下圖 2-4，不同於其他 CNN 架構如 Alexnet 或 VGG 透過增加深度，Inception 則在廣度上增加，也使它在 ImageNet 分類競賽打敗 VGG。

根據論文[5]，提出使用 Inception V3 進行預訓練模型( Pre-train model )，並對最後輸出層的全連接層與 Softmax 層進行遷移式學習( Transfer learning )，用來進行小鼠的疼痛辨識，是近期準確率最佳的方式，因此選擇以此作為本專題的對照組，用以評估實驗效果。




圖 2-4 Inception V3 架構

## 第三章 實驗方法

### 3.1 實驗架構

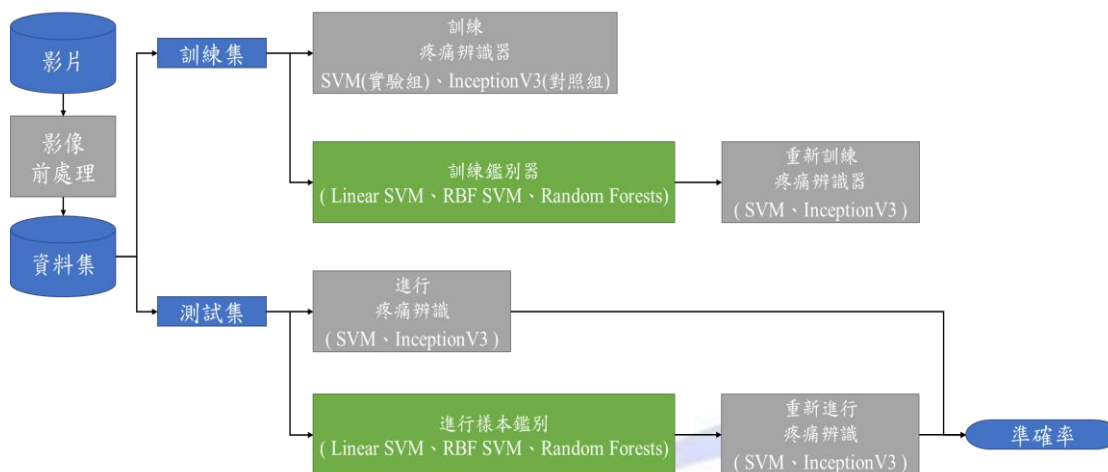


圖 3-1 實驗架構圖

本專題的架構，如上圖 3-1 所示，首先文獻[1]與文獻[5]分別提出以支援向量機(SVM)與卷積神經網路的 InceptionV3 兩種不同的演算法，對小鼠進行疼痛辨識，而本專題與其最大的差別在於，仿造生成對抗網路( GAN )的架構，在原先的架構上，新增一個鑑別器，對容易造成誤判的樣本進行鑑別，再重新訓練並進行疼痛辨識，以此方式對原先的架構進行改善。

訓練鑑別器的過程中，將會使用三種不同的演算法，分別為 Linear SVM、RBF SVM 以及 Random Forests，對資料集進行樣本鑑別後，再重新訓練疼痛辨識器，並根據結果，選出何者作為鑑別器的效果最佳。

最後本專題將根據疼痛辨識器的建構方式，將使用 SVM 的方式作為實驗組，使用 InceptionV3 的方式作為對照組，透過鑑別器的使用後，觀察實驗組的疼痛辨識準確率是否有所改善，並與對照組進行比較，觀察使用機器學習與神經網路的優缺點。

### 3.2. 影像前處理

為了之後的訓練，必須先進行影像前處理，需將小鼠的影片裁切成一張張的圖片，接著進行臉部特徵的抓取，找出含有圖片中含有臉部特徵的部分圖片，並進行特徵點的幾何特徵計算。

首先將影片透過 MATLAB 裁切成圖片，由於影片為高速攝影機以每秒 60 幀進行拍攝，因此 10 分鐘的影片將裁切成 36000 張圖片，接著使用 YOLO 演算法，將影像中同時含有小鼠的耳朵、眼睛以及鼻子等影像抓取出來，如下圖 3-2 所示。




圖 3-2 老鼠正臉圖

並根據耳朵、眼睛以及鼻子等特徵點的座標位置，進行歐式距離與角度的計算，取得之後訓練模型用的幾何特徵，如下圖 3-3，總共 8 個距離特徵、15 個角度特徵。



圖 3-3 臉部幾何特徵示意圖

### 3.3 訓練疼痛辨識器

#### 3.3.1 疼痛辨識器(SVM)

首先根據文獻[1]所提出，將處理好的資料集根據是否施打辣椒素，標記成疼痛或健康後，並劃分為訓練集和測試集。

接著將樣本的距離特徵進行標準化(Standardization)，使資料符合標準常態分佈，降低離群值來降低整體資料的影響。這部分採用的是 Z 分數標準化(Z-Score Standardization)，假設資料的平均數與標準差分別為  $\mu$  及  $\sigma$ ，其公式如下：

$$Z = \frac{X - \mu}{\sigma}$$

將 8 個距離特徵執行標準化，再以此作為輸入特徵，訓練支援向量機(SVM)，進行疼痛辨識。

最後參數調整的方式為，先透過隨機搜尋(Random Search)縮小範圍，再使用網格搜索(Grid Search)，在 Linear Kernel 的情況下，找到最理想的參數如下：

Linear Kernel SVM：  $C = 25$ 、 $\text{gamma} = \text{auto} = 1/n\_features = 1/8$ 。

#### 3.3.2 疼痛辨識器(InceptionV3)

根據論文[5]，以卷積神經網路的 InceptionV3 進行小鼠的疼痛辨識，以圖片作為輸入特徵進行訓練。首先將抓取好特徵的影像進行縮放，大小為  $128 \times 128$ ，並將資料進行正規化(Normalization)，將資料等比例縮放到  $[0, 1]$  區間中，公式如下：

$$X' = \frac{X - X_{min}}{X_{max} - X_{min}} \in [0, 1]$$

由於將影像轉換成矩陣時，是以 8 bits 為儲存單位，所以最大值=255、最小值為 0，因此想壓縮至  $[0, 1]$  區間內，只需將資料除上 255。透過正規化能夠使資料保持原有的特性，並提高模型訓練的收斂速度，可讓每個特徵值對結果做出相近程度的貢獻，不會出現權重失衡的現象。

最後根據文獻[5]，使用卷積神經網路的 InceptionV3，透過載入預訓練模型，獲得初始參數，再透過遷移式學習，將最後輸出層的全連接層與 Softmax 層重新訓練，此作法能夠以較少的樣本數，訓練一個完整的圖片辨識器。

過程中透過 early-stopping 監控驗證集的 loss 與 accuracy，最終選用的參數為下表 3-1：

表 3-1 InceptionV3 參數

參數	Batch size	Learning rate	Epochs
	100	0.0001	30~40



### 3.4 進行疼痛辨識

在訓練好的疼痛辨識器 SVM 與 InceptionV3 之後，對測試集進行疼痛辨識，並根據預測結果計算準確率，將其作為之後比較的數據。

### 3.5 訓練鑑別器

這部分為本專題的重點，透過仿照生成對抗網路( GAN )的架構，在原先的架構上，新增一個鑑別器，對容易造成誤判的樣本進行鑑別，以此重新劃分資料集，並根據結果觀察是否能對於原先的架構有所改善。

首先根據疼痛辨識預測結果是否正確，給予資料集新的標記，預測正確的樣本標記為 1；反之則標記為 0，並將其假設為容易造成誤判的樣本。接著根據文獻[3]與文獻[4]得到的想法，將特徵點之間的角度進行標準化( Standardization )，作為訓練鑑別器的輸入特徵。

訓練過程中，將分別選用以下三種演算法，Linear SVM、RBF SVM 以及 Random Forests 作為鑑別器，透過實驗的方式，找出何者作為鑑別器的效果最佳。

#### 3.5.1 鑑別器( Linear SVM )

將資料集劃分成訓練集與測試集後，將特徵點之間的角度作為輸入特徵，首先選用 Linear Kernel 的 SVM，作為鑑別器並進行訓練，觀察使用線性的方式下，對於原先的架構能否有所改善。在訓練的過程中，透過隨機搜索和網格搜索的方式，找尋最佳的參數，而最終選用的參數如下：

Linear Kernel SVM：  $C = 25$ 、 $\gamma = \text{default} = 1/(n\_features * X.\text{var}())$

#### 3.5.2 鑑別器( RBF SVM )

接著在第二種方式，則採用的是 RBF Kernel 的 SVM，嘗試加入非線性的方式，觀察其結果，是否對於疼痛辨識有所改善。在訓練的過程中，一樣透過隨機搜索和網格搜索的方式，最終選用的參數如下：

RBF Kernel SVM：  $C = 25$ 、 $\gamma = \text{auto} = 1/n\_features = 1/15$

#### 3.5.3 鑑別器( Random Forests )

第三種方式，則是根據文獻[2]得到的想法，採用隨機森林( Random Forests )作為鑑別器，透過加入非線性且不易過擬合的特性，觀察結果是否有所改善。訓練過程，一樣透過隨機搜索和網格搜索的方式，最終選用的參數如下：

Random Forests：  $n\_estimators = 40$ 、 $\text{max\_depth} = 80$

### 3.6 重新訓練疼痛辨識器

在鑑別器對資料集進行鑑別後，透過電腦鑑別出容易造成誤判的樣本，將預測結果為 0 的樣本移除，以此更新資料集，再重新訓練疼痛辨識器，訓練過程與先前相同，差別只在於資料集的重新劃分。

### 3.7 進行樣本鑑別

接著對測試集進行鑑別，分別載入先前訓練好的鑑別器，Linear SVM、RBF SVM 以及 Random Forests，透過電腦自動鑑別，將容易造成誤判的樣本移除，對資料集重新劃分。

### 3.8 重新進行疼痛辨識

將重新劃分的測試集，透過重新訓練好的疼痛辨識器，重新進行疼痛辨識，並根據預測結果，計算其準確率，作為最終的輸出。

最後針對使用鑑別器前、後的準確率進行比較，觀察實驗組的 SVM 進行疼痛辨識是否有所改善，並與對照組的 InceptionV3 進行比較，透過觀察實驗組與對照組的結果，討論本專題在使用機器學習與神經網路的優缺點。

## 第四章 實驗成果

### 4.1 資料集

本專題總共使用了六隻小鼠進行實驗，分別以 B、KT、MS、SWl、SWs 與 TW 命名。根據專家的描述，小鼠之間存在著個體差異，因此在考慮這個因素下，將實驗分成三個部分討論，以「個別小鼠、全體小鼠以及未知小鼠」，組成不同的資料集進行疼痛辨識，如下表所示：

表 4-1 資料集表格

資料集	訓練集	測試集	備註
個別小鼠	單隻的八成樣本	單隻的兩成樣本	獨立訓練
全體小鼠	全體的八成樣本	全體的兩成樣本	各取 2000 樣本
未知小鼠	五隻小鼠	一隻小鼠	輪流替換測試集

討論在不同資料集下，進行疼痛辨識，透過比較實驗組與對照組的結果，驗證本專題，是否透過鑑別器的架構，使原先架構的準確率有所改善。

討論結果的過程，將分成兩個階段，第一階段，針對不同的辨識器，討論資料集更新後的數量以及疼痛辨識的準確度提升程度；第二階段，將針對實驗組與對照組進行比較，再透過減少訓練樣本數量，討論其準確度以及通用性。

### 4.2 實驗結果

#### 4.2.1 個別小鼠

首先根據專家所言，小鼠間存在著個體差異，因此將六隻小鼠分成六個獨立資料集，個別進行疼痛辨識的訓練與預測，透過觀察結果，比較不同辨識器下，實驗組與對照組的疼痛辨識準確率。

根據先前的說明，將使用三種方式架構鑑別器，分別為 Linear Kernel SVM、RBF Kernel SVM 以及 Random Forests，從下表 4-2 可觀察到，不論使用哪種方式，都將使資料集數量下降，但還可保留五至六成的樣本數，並不會造成大量的樣本流失。

表 4-2 個別小鼠：資料集數量表

Discriminator Classifier	Number of Dataset					
	B	KT	MS	SWl	SWs	TW
Non	9522	2914	14676	15110	8234	9926
SVM1(linear)	5244	1766	9672	10794	5064	7544
SVM1(rbf)	6152	1732	9604	11276	5656	7554
RFC	5746	1206	10028	10276	4126	5362

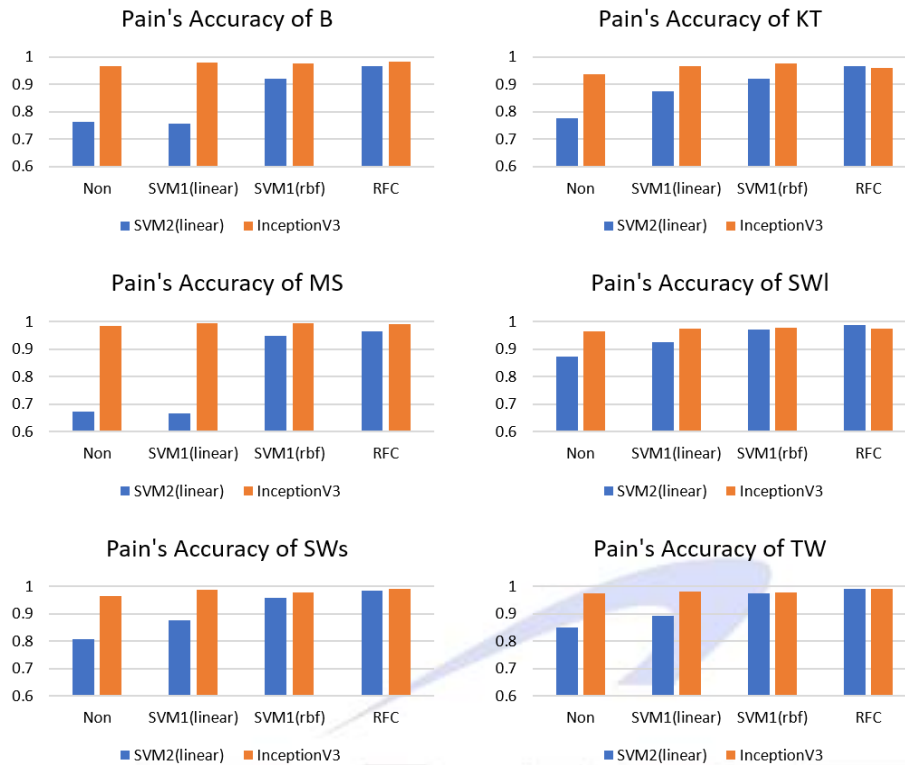


圖 4-1 個別小鼠：疼痛辨識準確率

並根據上圖 4-1 表示，實驗組與對照組的準確率，實驗組原先的準確率如同文獻[1]所示，只能達到七至八成，但在鑑別器使用隨機森林(Random Forests)的幫助下，能獲得極大的改善，將其準確率拉升至九成甚至九成五，也證明了樣本中確實存在著容易導致誤判的樣本。


#### 4.2.2 全體小鼠

在部分為不考慮個體差異的情況下，將所有的小鼠組成一個資料集進行實驗，並且在此方式下，觀察實驗組採用機器學習的方式，是否能夠學習具有多樣性的訓練資料。


透過鑑別器更新資料集後，實驗結果為下表 4-3，其結果與個別小鼠的結果沒有太大的變化，資料集經過鑑別器將容易誤判的樣本移除後，樣本數也還是能夠維持在五至六成，沒有大量的流失。

表 4-3 全體小鼠：資料集數量表


Discriminator Classifier	Number of data	
	Number	Rate
Non	12000	100%
SVM1(linear)	5240	43.7%
SVM1(rbf)	6280	52.3%
RFC	7060	58.8%




(a) 訓練樣本數：8000 筆



(b) 訓練樣本數：4000 筆



(c) 訓練樣本數：3000 筆



(d) 訓練樣本數：2000 筆

圖 4-2 全體小鼠：疼痛辨識準確率

首先將不同方式下的實驗結果，以上圖 4-2 所示，由圖 4-2(a)可觀察到，在全部小鼠組成一個資料集的情況下，實驗組的支援向量機( SVM )依然可透過鑑別器，獲得巨大的改善，將其準確率由六成提升至九成。

並觀察減少訓練樣本數的情況下，實驗組與對照組準確率的變化，發現當訓練樣本數減少至 3000 與 2000 筆時，實驗組的支援向量機( SVM )在隨機森林( Random Forests )的幫助下，能獲得更好的準確率，驗證了機器學習能夠以較少的訓練資料進行學習，並不會因此降低其效果。

從個別小鼠與全體小鼠的實驗中，可得知使用隨機森林( Random Forests )作為鑑別器，能夠使支援向量機( SVM )獲得極大的改善，其準確率在訓練樣本較少時，甚至能超過 InceptionV3。



### 4.2.3 未知小鼠

在現實的情況下，模型在訓練的過程中，測試集與訓練集需要完全獨立，才能保證其模型具有通用性，所以在考慮此情況下，分次將其中一隻小鼠當作測試集，將剩餘的五隻小鼠作為訓練集，觀察其結果。

表 4-4 未知小鼠：資料集數量表

Discriminator Classifier	Number of Testing Set					
	B	KT	MS	SWI	SWs	TW
Non	2000	2000	2000	2000	2000	2000
SVM1(linear)	1015	1129	1318	128	689	1579
SVM1(rbf)	1094	1258	1030	480	541	1105
RFC	954	1184	925	612	920	891

首先將更新資料集後的實驗結果，以上表 4-4 表示，不論使用何種方式的鑑別器，都不會流失大量的樣本數，依然維持在五成至六成，可驗證鑑別器並不會受到測試集獨立的影響。

並將實驗組與對照組的準確率，以下表 4-5 所示，並將準確率較高的結果以綠色標記，分別觀察訓練樣本數為 10000 筆、4000 筆以及 2000 筆的準確率，過程中都將使用隨機森林( Random Forests )作為鑑別器。

表 4-5 未知小鼠：疼痛辨識準確率

Pain's Accuracy with Discriminator (Random Forests)						
訓練樣本數	10000 筆		4000 筆		2000 筆	
	SVM	InceptionV3	SVM	InceptionV3	SVM	InceptionV3
B	63.84%	72.33%	69.26%	65.27%	67.70%	60.91%
KT	26.35%	73.40%	23.91%	51.85%	23.89%	65.35%
MS	52.00%	78.59%	66.35%	58.13%	62.74%	54.14%
SWI	61.93%	67.48%	62.39%	73.13%	68.85%	69.53%
SWs	50.98%	69.67%	54.72%	44.65%	50.45%	48.06%
TW	69.81%	67.79%	74.27%	63.49%	69.52%	46.88%

在 10000 筆的情況下，可以觀察到 InceptionV3，雖然擁有較高的準確率，但是與先前的個別小鼠以及全體小鼠相比，卻出現大幅度的下降，可推測是神經網路發生了過擬合，當遇上未知的樣本，則不能夠準確地進行辨識。

並在訓練資料下降至 4000 與 2000 筆時，可觀察到 SVM 有 4 組較高的準確率，是贏過 InceptionV3，此外就算下降至 2000 筆資料，SVM 的準確率也與先前無太大的差距；反之，InceptionV3 則出現更大幅度的下降。

因此可以驗證實驗組使用機器學習，相較於使用神經網路的對照組，的確能透過較少的關鍵樣本進行學習，並獲得較高的通用性與準確率。

# 第五章 結論

## 5.1 總結與未來展望

本專題透過仿照生成對抗網路( GAN )的架構，以及結合隨機森林(Random Forests)，對原先只使用支援向量機(SVM)的架構進行修改，以機器學習的方式作為實驗組，並根據文獻[5]提出神經網路的方式作為對照組，進行驗證後，最終得到以下幾點：

1. 能使支援向量機( SVM )進行疼痛辨識的準確率由八成提升至九成五。
2. 在使用隨機森林( Random Forest )作為鑑別器時，支援向量機( SVM )能透過較少的訓練樣本，獲得較高的準確率以及通用性。
3. 機器學習相對於神經網路較能避免過擬和的發生。
4. 機器學習相較神經網路所需較少的時間成本。

而在專題製作的過程中，也發現了可能造成誤差的幾點問題，如下：

1. 影像背景極為相似，容易導致模型學習到背景特徵，造成誤差。
2. 使用 YOLO 抓取臉部特徵時，沒有間隔取樣，容易在短時間內造成過度取樣。

以上幾點都是能夠有所改進的地方，並隨著科技的進步，或許能夠找到更好的方式進行疼痛辨識，像是追蹤動物的動態範圍或是根據形體變化進行分析，以不同的角度去重新架構，得到更多元的結果。

## 第六章 參考文獻

- [1] 陳毓峯 “Detection and Quantification of Mice in Pain Utilizing Machine Learning Algorithms”
- [2] Najmeh Samadiani, Guangyan Huang, Borui Cai, Chi-Hung Chi, Yong Xiang and Jing He. “A Review on Automatic Facial Expression Recognition Systems Assisted by Multimodal Sensor Data”
- [3] Liu, L.; Gui, W.; Zhang, L.; Chen, J. “Real-time pose invariant spontaneous smile detection using conditional random regression forests”
- [4] Y. Liu, J. Chen, Z. Su, Z. Luo, N. Luo, L. Liu, K. Zhang. “Robust head pose estimation using Dirichlet-tree distribution enhanced random forests”
- [5] AH Tuttle, MJ Molinaro, JF Jethwa, SG Sotocinal, JC Prieto, MA Styner, JS Mogil and MJ Zylka1. “A deep neural network to assess spontaneous pain from mouse facial expressions”
- [6] Christian Szegedy, Wei Liu, Yangqing Jia, Pierre Sermanet, Scott Reed, Dragomir Anguelov, Dumitru Erhan, Vincent Vanhoucke, Andrew Rabinovich. “Going Deeper with Convolutions”
- [7] Leo Breiman. “Random Forests”
- [8] Joseph Redmon, Santosh Divvala, Ross Girshick, Ali Farhadi. “You Only Look Once : Unified, Real-Time Object Detection”